

A-Level Agentic Tutor 智能辅导系统实现指导

面向中国 A-Level 高中生的中英双语学习 Agent：
支持教材问答、题目问答、图片识题、作业批改、提示优先、引用可解释。

第一版科目

9701 Chemistry 9702 Physics 9708 Economics
9709 Mathematics

推荐 MVP 形态

Web App 先行，后期用同一套后端扩展桌面端。
LLM 只使用中国/国内可用的开源模型 API，不做本地部署。

目标使用者：学习 Cambridge A-Level 的中国高中生，尤其是英语学科表达和抽象概念理解较弱的学生。

预算假设：模型与 OCR API 月预算不超过人民币 20 元；基础设施、域名、短信等不计入此 API 预算。

资料依据：Cambridge 官方考纲、Alibaba Cloud Model Studio 百炼文档、Tencent OCR 文档、SiliconFlow 文档、EEF 教育研究资料及中国数据合规公开文件。价格与政策可能变化，上线前需要再次核对。

生成日期：2026-05-26

目录

1. 一页版结论
2. 产品定位与 MVP 边界
3. 学习体验设计：先提示，再答案
4. 系统架构：窄 Agentic，而不是重型多 Agent
5. 图片识题与作业批改流水线
6. 知识库、RAG 与引用可解释性
7. 模型与 API 选型
8. 成本模型：如何守住每月 20 元
9. 数据模型与后端接口
10. 提示词模板与批改模板
11. MVP 开发路线图
12. 测试、质量、安全与合规
13. 后续路线图与简历包装
14. 资料来源

1. 一页版结论

最推荐的 MVP 方案：做一个工具路由式 Web App，而不是一开始就做复杂自治多 Agent。核心是：学生上传题目或作业图片，系统先做 OCR/视觉解析，再路由到不同的讲解器、批改器和引用检索器，最后输出中英双语、提示优先、可引用追溯的讲解和评分。

产品一句话	给中国 A-Level 学生用的“会识题、会提示、会讲人话、会批改、会引用来源”的 bilingual agentic tutor。
首发科目	9701 Chemistry、9702 Physics、9708 Economics、9709 Mathematics。
首发平台	Web App。后续桌面端可以用 Tauri/Electron 复用后端。
默认技术栈	Next.js + TypeScript + Tailwind + FastAPI + PostgreSQL + Redis + OSS/COS + Alibaba Cloud Model Studio 百炼。
默认模型组合	Qwen2.5-7B 或 Qwen3-8B 做日常讲解；Qwen2.5-Math-7B 做数学与符号推理；Qwen-VL-OCR 做低价 OCR；Qwen3-VL-8B 做图表和困难图片 fallback；腾讯 OCR 作为试卷切题/公式识别的可选 fallback。
最关键产品原则	先给巧妙提示，再给完整答案；所有正式解释都必须带来源引用；图片题必须先结构化，再批改。
预算判断	20 元/月 API 预算可以支撑私测和小规模校内 pilot，但不适合无门槛公开大规模使用。必须做短输出、缓存、限流和按需生成完整答案。

最重要的工程判断：“Agentic” 在这个项目里不应该理解成很多 Agent 互相讨论。MVP 里应理解成：一个稳定的 Orchestrator 根据题目类型、图片置信度、学科、预算和用户意图，选择最便宜且足够可靠的工具链。

2. 产品定位与 MVP 边界

2.1 你真正要解决的问题

中国 A-Level 学生常见的问题不是“完全没资料”，而是资料太散、英文表达陌生、抽象概念听不懂、做题套路没有被显式总结、错题没有形成可复用的学习路径。你的工具应该抓住这四个痛点：

- 把抽象概念讲成人话：**用比喻、类比、图像化语言让学生先理解本质。
- 保留 Exam English：**最终作答语言、学科关键词、command words、公式和单位必须保留英文训练。
- 会看题、会看答案：**不仅能读题干，还要能读图片、表格、图像、公式、学生手写步骤。
- 可解释：**讲解要能追溯到考纲、公式表、老师讲义或概念库，而不是“AI 觉得”。

2.2 MVP 必须做什么，不做什么

模块	MVP 必须做	MVP 记录但不做完整 UI	MVP 暂缓
题目问答	文字输入、图片上传、提示优先、完整解答、引用来源	按学科/主题记录学生互动	完全自动生成个性化学习计划
教材问答	基于预置考纲与概念讲义 RAG 回答	记录用户常问概念	允许学生自由上传任意教材并自动建库
图片识题	印刷体 OCR、公式识别、图表/图像 fallback、低置信提示	保存 OCR 置信度与问题区域	完美识别所有潦草手写化学结构
作业批改	单题批改、短答案/计算题/基础 essay feedback、单位与方法检查	错因标签入库	高风险长 essay 直接给最终高置信分数
错题本	暂不做完整 UI	必须记录错因、题型、学科、引用、反馈	智能复习计划、间隔重复系统
用户画像	暂不做复杂画像	记录语言偏好、hint 使用率、错误类型	学习风格推断、长期推荐系统

2.3 为什么 Web App 先行

Web App 对 MVP 最友好：不用处理桌面端安装、更新、系统权限和跨平台差异，学生打开链接即可用，老师也容易在课堂或自习时试用。你后期想做桌面端，可以把桌面端当作“壳”，继续复用 FastAPI 后端、数据库、OCR/LLM 路由和知识库。

建议首发形态：响应式 Web App，手机上传拍照题，电脑端看讲解和批改报告。桌面端留到有真实用户反馈之后再做。

3. 学习体验设计：先提示，再答案

这个产品的核心差异不是“能不能答题”，而是“能不能像好老师一样让学生产生顿悟”。因此回答结构必须稳定，不能让模型自由发挥。

3.1 每次回答的标准形状

阶段	学生看到什么	设计目的
1. 重述问题	用一句中文/英文把题目问什么说清楚	防止学生连题都没看懂

2. 巧妙提示	给一个比喻、检查点或第一步方向	保留学生自主思考空间
3. 解题计划	列出 2-4 个步骤	训练做题套路
4. 完整答案	分步 working、公式、单位、最终答案	提供可模仿的 exam-style solution
5. 为什么得分	按 mark point 解释哪里拿分	把“会做”转为“会拿分”
6. 常见坑	指出单位、符号、定义、因果链等易错点	服务后续错题本和用户画像
7. 来源引用	显示考纲/公式表/讲义片段来源 chip	满足 explainable 要求

3.2 中英双语模式

模式	主要语言	必须保留英文的部分	适合场景
中文优先	中文讲解为主	学科关键词、公式、单位、final answer、command words	概念初学、英语弱的学生
英文优先	英文解释为主，关键处加中文 gloss	全部核心术语	考前训练和强一点的学生
Exam English	全英文	全部	限时练习、模拟考试
Hover Gloss	界面功能而非回答模式	鼠标悬停关键词显示中文解释和记忆法	帮助学生记住英文术语

3.3 英文记忆功能建议

你可以做一个很有特色的功能：**Exam English Memory Cards**。每次回答中自动抽取 3-5 个 A-Level 高频英文表达，给中文解释、考试用法和记忆钩子。

英文词/短语	中文解释	考试用法	记忆钩子
evaluate	评价，不能只解释一边	需要优点、限制、条件、最终判断	e-value-ate：给这个观点“估值”
hence	因此，所以	用于数学/物理推导的下一步	看到 hence，前面一定有依据
limiting reagent	限制反应物	决定产物最大量的反应物	像火锅里最先用完的肉，决定最多能做几份
resultant force	合力	所有力合起来的净效果	拔河最后真正推动人的那股总力

3.4 示例：不同科目的比喻库

科目	主题	比喻	先给提示	完整答案风格
9701 Chemistry	Equilibrium and pressure	拥挤电梯：压力升高时，平衡偏向气体粒子数更少的一侧。	先数两边 gas moles，不要急着背结论。	Increasing pressure shifts the equilibrium to the side with fewer moles of gas. 再结合方程解释产率变化。
9702 Physics	Energy	高度金币变速度金币：重力势能转化为动能。	如果不考虑空气阻力，先想 energy，比 SUVAT 更简单。	$mgh = \frac{1}{2}mv^2$, mass cancels, 最后检查单位。
9708 Economics	Currency depreciation	贬值像给出口贴打折标签，同时给进口贴涨价标签。	分两扇门想：外国买家看到什么？本国消费者看到什么？	解释 export cheaper、import dearer，再加 elasticity 与 evaluation。
9709 Mathematics	Inclined plane	重力被拆成“压住斜面”和“沿斜面滑下”的两部分。	不要分解 normal reaction，要分解 weight。	沿斜面： $mg \sin \theta = ma$ ，所以 $a = g \sin \theta$ 。

4. 系统架构：窄 Agentic，而不是重型多 Agent

这个项目的架构重点是可控、便宜、能 debug。MVP 不建议做 “Planner Agent + Solver Agent + Critic Agent + Teacher Agent” 这种多 Agent 循环，因为它会快速消耗预算，并且批改结果不稳定。你应该做的是工具路由式 Agentic 系统。




图 1：推荐 MVP 架构。一个 Orchestrator 根据题目类型、图片质量和预算选择 OCR、视觉、讲解、批改和引用工具。

4.1 推荐技术栈

层级	推荐选择	原因
前端	Next.js + TypeScript + Tailwind + shadcn/ui	快、美观、简历价值高；适合做图片上传、对话、批改报告。
后端	FastAPI + Pydantic + SQLAlchemy/SQLModel	适合 AI 编排、异步任务、schema 校验，Python 生态适合 OCR/CV。
数据库	PostgreSQL	结构化数据、JSONB、引用、日志、用户进度都能存。
缓存/队列	Redis	缓存提示词、OCR 结果、异步 homework batch job。
对象存储	Alibaba OSS 或 Tencent COS	存原始图片、PDF、批改报告、渲染结果。

模型 API	Alibaba Cloud Model Studio 百炼为主，SiliconFlow/Tencent OCR 可选	国内可用、OpenAI-compatible、Qwen 开源模型族、OCR/VLM/文本模型都能接。
部署	一台小型云服务器 + Docker Compose 起步	成本低、可控、简历项目足够展示工程能力。

4.2 Agentic 编排方式

Orchestrator 的输入是用户请求、图片/文本、学科设置、预算状态和历史上下文。输出是一个短的工具执行计划。例如：

```
{`User uploaded image + wants grading
- classify subject and modality
- run image preprocessing
- call qwen-vl-ocr
- if graph/table/formula confidence low, call qwen3-vl fallback
- normalize to CanonicalQuestion
- retrieve syllabus/concept citations
- call grading model
- assemble feedback with marks, sources and misconception tags`}
```

4.3 核心模块职责

模块	职责	输入	输出
QuestionClassifier	判断科目、题型、是否需要视觉、是否可直接文本回答	文本、图片元数据、OCR 摘要	subject、question_type、modality、confidence
OcrPipeline	图片预处理、OCR、公式和区域解析	图片或 PDF 页面	OCR text、bbox、formula LaTeX、置信度
QuestionNormalizer	把 OCR 结果整理成统一题目结构	raw OCR + regions	CanonicalQuestion JSON
CitationEngine	从考纲、公式表、讲义中检索相关片段	subject、topic、command word	SourceSnippet[]
TutorEngine	生成提示、分步讲解、比喻和 exam-style answer	CanonicalQuestion + sources	HintResponse / SolutionResponse
GraderEngine	批改学生答案，输出分数、错误、改进建议	题目、学生答案、rubric、sources	GradeResult JSON
ErrorLogger	记录错因，为后续错题本和画像做准备	GradeResult + usage events	ErrorLog

BudgetGuard	控制每日/每月 API 调用、fallback 频率和输出长度	用户、模型、请求类型	allow / degrade / reject
-------------	---------------------------------	------------	--------------------------

5. 图片识题与作业批改流水线

第一版必须支持图片识题和批改，这是项目难点，也是简历亮点。工程上要把“看图”和“批改”拆开，不能直接把一张图丢给大模型让它自由回答。



图 2：图片题处理流水线。先用便宜 OCR，只有低置信或图表题才进入视觉 fallback。

5.1 为什么要分阶段

错误做法	问题	正确做法
整张图片直接交给大 VLM 输出答案	贵、不可控、难 debug、引用困难	先 OCR 和结构化，再调用讲解/批改模型
不保存 OCR 中间结果	学生质疑批改时无法复盘	保存 raw OCR、normalized question、bbox、置信度
低置信也硬答	会严重伤害用户信任	明确提示“图片不清楚”，要求重拍或手动补全
批改时只看最终答案	A-Level 很多分数在 method 和 units	检查过程、公式、单位、符号、解释链

5.2 单题图片流程

1. 学生上传题目图片。
2. 前端检查图片是否过小、过暗、过糊、旋转过大。
3. 后端用 OpenCV 做裁边、纠偏、压缩、对比度增强。注意：这不是本地模型部署，只是确定性图像处理。
4. 调用 Qwen-VL-OCR 提取题干、公式、表格文字、题号、子问。
5. 如果检测到坐标轴、曲线、实验装置、经济图、化学结构，或者 OCR 置信度低，再调用 Qwen3-VL-8B 做视觉补充。
6. 把结果归一化成 CanonicalQuestion JSON。
7. 检索相关考纲/公式表/讲义片段。
8. 按用户按钮选择：先提示、完整解答、批改作答。

5.3 作业批改流程




图 3：学生从上传题目到获得提示、答案、评分和错因标签的完整流程。

作业批改比单题更复杂，因为一页里可能有多道题、多种题型和学生手写步骤。MVP 可以先做“半自动”：系统自动切题并批改，低置信题进入“需要人工确认/重拍”的状态。

状态	含义	前端显示
Ready	识别清晰，可以批改	绿色标签，允许查看反馈
Needs better image	图片模糊、过暗或部分缺失	提示重拍，并给拍照建议

Low confidence	OCR 或视觉理解不确定	黄色标签，展示系统读到的题目让学生确认
Reviewed	已批改并保存错因	显示分数、反馈、引用、下次练习建议

5.4 不同题型的批改重点

题型	批改重点	低置信触发条件
MCQ	选项是否正确、排除逻辑是否合理	选项文字识别不完整
Structured calculation	公式、代入、单位、有效数字、最终答案	公式/手写数字不清楚
Short explanation	关键词、因果链、是否回答 command word	句子断裂或关键词缺失
Graph / diagram	坐标轴、趋势、梯度、实验装置、图像结论	轴标签、曲线、标注不清
Economics essay	定义、图、因果链、evaluation、结论	长手写文本 OCR 不可靠

6. 知识库、RAG 与引用可解释性

你的产品必须做到 explainable。最安全、最清晰的做法不是让模型上网乱搜，而是建立一个受控的 Citation Store：官方考纲、公式表、学校自编讲义、老师整理的 mark point 和术语表。

6.1 资料来源分层

层级	内容	是否建议进入 MVP 知识库	备注
官方考纲	9701/9702/9708/9709 syllabus	强烈建议	用作 topic mapping 和引用来源。
公式表/数据手册	数学/物理/化学公式与常数	建议	适合直接引用，帮助学生检查公式来源。
学校自编讲义	老师允许使用的笔记、总结、错题模板	强烈建议	版权风险最低，也是母校试用最有价值的内容。
Cambridge past papers / mark schemes	真题与 mark scheme	谨慎	不要公开再分发。可在学校许可范围内供课堂内部使用，需遵守 Cambridge 政策。
网络资料	公开博客、题库、视频	不建议首版依赖	质量、版权、稳定性和引用可信度都较难控制。

6.2 Citation Store 设计

```
{`SourceSnippet = {
  id: "9702_energy_work_power_001",
  subject_code: "9702",
  topic: "Work, energy and power",
  source_type: "syllabus | formula_sheet | school_note | glossary",
  title: "Cambridge International AS & A Level Physics 9702 syllabus",
  page_or_section: "Subject content: Work, energy and power",
  text: "...short approved snippet...",
  license_note: "official syllabus / school-owned note",
  url_or_file_ref: "...",
  version: "2025-2027"
}}`}
```

6.3 回答里的引用样式

不要在回答里堆长链接。前端展示成小 chip 即可：

9702: Work, energy and power

Formula Sheet: mechanics

School Note PH-12

点击 chip 后弹出简短来源：标题、页码/章节、片段、URL 或内部文件名。这样既 explainable，又不会破坏学生阅读体验。

6.4 RAG 的最小流程

- 1. QuestionClassifier 识别 subject_code 与 topic tags。
- 2. CitationEngine 用 BM25 + embedding 双路召回相关片段。
- 3. 只取 3-6 条短片段放进模型 prompt，避免长上下文浪费钱。
- 4. 模型必须只引用提供的 source ids，不能编造来源。
- 5. 前端渲染引用 chips，并在日志中保存 answer_id 到 source_ids 的映射。

7. 模型与 API 选型

你的限制是：不能本地部署，最好是中国开源模型 API，预算很低。因此核心策略是：**便宜文本模型做常规讲解，便宜 OCR 做识题，视觉模型只做 fallback，数学模型只在需要时调用。**

7.1 推荐提供商

提供商	用途	优点	风险/限制	建议
Alibaba Cloud Model Studio 百炼	主力文本、OCR、视觉、数学模型	国内云服务，OpenAI-compatible，Qwen 模型族，模型和计费文档完整，支持缓存和 batch。	价格、模型别名、免费额度可能变化；需要上线前复核。	默认主提供商
SiliconFlow	开发测试、备用模型、A/B 测试	模型种类多，接入方式简单，部分模型有免费/低价路线。	生产稳定性、限流和免费策略不应作为核心假设。	做开发备份，不做批改核心
Tencent OCR	公式 OCR、试卷切题、教育场景 OCR fallback	教育 OCR 能力强，支持题目识别、公式/数学 OCR、坐标区域。	付费切题和批改较容易超出 20 元/月预算。	只做 pilot fallback 或评测基准

7.2 推荐模型路由

任务	默认模型/服务	原因	触发条件
普通问答/提示	Qwen2.5-7B-Instruct 或 Qwen3-8B	便宜，足够做短提示和通俗讲解。	文本题、OCR 清晰题、概念问答。

完整解答	Qwen2.5-7B / Qwen3-8B	输出能力足够，成本可控。	用户点击“显示完整答案”。
数学/符号批改	Qwen2.5-Math-7B-Instruct	数学推理和符号处理更适合。	9709、9702 计算题、复杂代数步骤。
OCR	Qwen-VL-OCR	适合低价图片文字与结构提取。	所有图片题默认先走 OCR。
图表/装置 fallback	Qwen3-VL-8B-Instruct	处理坐标轴、实验图、经济图、复杂表格。	OCR 低置信或 question has graph/diagram。
极困难视觉题	Qwen3-VL-30B-A3B-Instruct	更强但更贵。	只在 teacher/premium/retry 模式使用。

7.3 模型版本策略

批改路径不要使用会漂移的 **latest alias**。生产环境要固定模型 snapshot、prompt version、rubric version 和 citation-bank version，否则你无法解释为什么同一题昨天和今天评分不同。

建议日志里保存：

```
{`model_provider: "bailian"
model_id: "qwen2.5-math-7b-instruct"
prompt_version: "grader_v0.3.2"
rubric_version: "9709_calc_v0.2"
citation_bank_version: "cie_2025_2027_v1"
ocr_pipeline_version: "ocr_v0.4"}`}
```

8. 成本模型：如何守住每月 20 元

20 元/月模型 API 预算不是不能做，但只能支撑私测、小规模校内 trial 或 founder 自用。公开给大量学生免费使用一定会超。关键是设计产品时默认节流，而不是上线后再补救。

8.1 单次操作粗略成本

操作	假设调用	官方价格依据	粗略成本
提示优先回答	约 1500 input + 250 output, Qwen2.5-7B	约 ¥0.5/M input, ¥1/M output	约 ¥0.001
完整分步解答	约 2200 input + 700 output, Qwen2.5-7B	同上	约 ¥0.0018
数学批改	约 1800 input + 500 output, Qwen2.5-Math-7B	约 ¥1/M input, ¥2/M output	约 ¥0.0028

图片 OCR	约 2000 image/input + 800 output, Qwen-VL-OCR	约 ¥0.3/M input, ¥0.5/M output	约 ¥0.001
视觉 fallback	约 2300 input + 400 output, Qwen3-VL-8B	约 ¥0.5/M input, ¥2/M output	约 ¥0.0019

说明：这是根据研究时的公开价格和合理 token 假设得到的估算。真实成本会受图片分辨率、输出长度、重试、模型价格变化影响。

8.2 月预算分配建议

预算池	建议金额	控制策略
核心问答与提示	¥8	默认短提示，完整答案按需生成。
OCR 识题	¥4	图片压缩、缓存 OCR 结果，同图不重复识别。
批改	¥4	只对学生提交的 attempt 做批改，不自动批改所有题。
视觉 fallback	¥2	只在低置信/图表/装置题启用。
重试与意外	¥2	每日限额、单用户限额、异常报警。

8.3 成本控制规则

- 1. **提示优先**：默认只返回短 hint，不直接生成长答案。
- 2. **完整答案按需**：只有用户点击“显示完整答案”才调用 full solution。
- 3. **OCR 结果缓存**：同一张图 hash 相同则复用结果。
- 4. **小模型优先**：文本清晰时绝不调用 VLM。
- 5. **图片压缩**：长边 1280-1600 px 通常足够，避免高分辨率图片浪费 tokens。
- 6. **输出长度上限**：hint 150-250 字，完整答案按题型控制 500-900 字。
- 7. **按用户设置月额度**：免费用户每天 5-10 次图片题，老师/测试账号更高。
- 8. **批处理走 batch**：错题总结、周报、后台分析放到低价 batch 或夜间任务。

商业化建议：母校试用阶段可以免费，但必须做 usage dashboard。真正开放时可以采用“学校付费 + 学生低价包月 + BYOK 自带 API key”的组合，否则 20 元/月无法覆盖真实流量。

9. 数据模型与后端接口

数据模型要为两个未来功能提前铺路：错题本和用户画像。因此即使 MVP 不做完整 UI，也要从第一天记录题型、错因、引用、置信度和模型版本。

9.1 CanonicalQuestion JSON

```
{
  "question_id": "q_9709_demo_001",
  "subject": "9709",
  "question_type": "structured_calculation",
  "language_mode": "zh_first",
  "stem_text": "A block rests on a smooth plane inclined at 30 degrees...",
  "subparts": [
    { "label": "(a)", "marks": 2, "target_skill": "resolve_forces" }
  ],
  "diagram_regions": [
    { "bbox": [120, 88, 420, 360], "kind": "diagram" }
  ],
  "formula_regions": [
    { "bbox": [460, 102, 700, 220], "latex": "F = ma" }
  ],
  "ocr_confidence": 0.93,
  "source_refs": ["9709_mechanics_component"],
  "needs_visual_reasoning": false
}
```

9.2 核心数据库表

表	作用	关键字段
users	用户账号与基础设置	id, email, role, preferred_language_mode, created_at
assets	上传文件和处理结果	id, user_id, object_key, mime_type, sha256, width, height, exif_stripped
questions	题目主表	id, user_id, subject_code, question_type, raw_text, normalized_text, canonical_json, ocr_confidence
answers	AI 讲解、批改、提示结果	id, question_id, answer_mode, language_mode, solution_text, score_awarded, rubric_json, citations_json

annotations	图片区域、公式、图表、学生作答区域	id, question_id, asset_id, region_type, bbox_json, text_value, latex_value, confidence
source_snippets	引用知识库片段	id, subject_code, topic, source_type, title, section, text, url_or_file_ref, version
error_logs	错因日志	id, user_id, question_id, subject_code, error_family, error_atom, severity, evidence_json
usage_events	成本与行为统计	id, user_id, route, model_id, input_tokens, output_tokens, cost_estimate, latency_ms

9.3 错因标签体系

error_family	例子	用途
concept	equilibrium direction misunderstood, elasticity confused	后续错题本按概念聚类
method	wrong formula, missing intermediate step	判断是否需要方法训练
algebra	rearrangement error, sign error	数学基础问题
units	wrong SI unit, missing unit conversion	物理/化学高频扣分点
diagram_reading	axis read wrongly, gradient mistaken	图表题专项训练
essay_structure	definition missing, no evaluation	经济 essay 训练
translation	misread command word, confused keyword	中英双语学习画像
carelessness	copied number wrongly, final answer not boxed	学习习惯反馈

9.4 后端 API

Endpoint	方法	用途	备注
/uploads/presign	POST	获取图片/PDF 上传 URL	避免文件直接走后端内存
/questions/parse	POST	OCR + 分类 + 结构化	大作业异步
/tutor/hint	POST	返回提示	默认短输出
/tutor/solve	POST	返回完整答案	按需调用
/grading/grade	POST	批改学生答案	输出 JSON + 可读反馈
/homework/submit	POST	提交整页/多页作业	返回 job_id
/homework/<job_id>	GET	查询批改进度	poll 或 SSE
/progress/summary	GET	学习概览	MVP 可先简单展示

10. 提示词模板与批改模板

提示词要短、稳定、可版本化。不要每次把一大堆说明塞给模型。系统 prompt、rubric 和引用格式要尽量复用，以便缓存和稳定输出。

10.1 Hint Prompt

```
{`System:
You are an A-Level tutor for Cambridge subjects 9701/9702/9708/9709.
Teach in {language_mode}. Use simple sentences. Keep exam terms in English.
Give only:
1) one-line core idea
2) one clever hint
3) one next step
Do NOT reveal the full solution unless asked.
If OCR/image is unclear, say exactly what is unclear.

User:
Subject: {subject}
Question type: {question_type}
Question: {question_text}
Student attempt: {student_attempt_or_blank}
Sources: {retrieved_snippets}`}
```

10.2 Full Solution Prompt

```
{`System:
You are an exam-focused A-Level tutor.
Teach in {language_mode}; preserve formulas, command words and final answer in English.
Output exactly in this order:
1. Core idea
2. Metaphor
3. Step plan`}
```

4. Worked solution
5. Final exam-style answer
6. Why this gets marks
7. Common mistake
8. Sources

Rules:

- Simple language
- Show calculations clearly
- Use one memorable metaphor if suitable
- Cite only from provided sources
- If the image is ambiguous, mark low confidence

User:

{canonical_question_json}

Sources:

{retrieved_snippets}``}

10.3 Grading Prompt

{`System:

You are a cautious A-Level grader, not a generous chatbot.

Score according to the rubric and explain point-by-point.

If handwriting/OCR is uncertain, lower confidence instead of guessing.

Rubric dimensions:

- Correctness
- Method / reasoning
- Units / notation / diagram labels
- Exam communication

Return JSON only:

```
{
  "score_awarded": 0,
  "score_max": 0,
  "confidence": 0.0,
  "verdict": "",
  "strengths": [],
  "mistakes": [],
  "misconception_tags": [],
  "next_step": "",
  "citations": []
}
```

User:

Question: {canonical_question}

Expected method / mark points: {marking_template}

Student answer: {student_answer}

Sources: {retrieved_snippets}``}

10.4 不同题型的输出模板

题型	输出模板
MCQ	核心概念 -> 排除提示 -> 正确选项 -> 一句话理由 -> 常见误区

计算题	核心公式 -> 步骤计划 -> 分行 working -> boxed final answer -> mark points
解释题	核心概念 -> 比喻 -> 因果链 -> concise exam answer -> keyword check
图表题	读坐标/趋势 -> 关键数值/形状 -> 推论 -> 常见读图错误
Economics essay	定义 -> 图/机制 -> 分析链 -> evaluation -> conclusion

10.5 通用批改权重

维度	默认权重	说明
Correctness	40%	最终答案或结论是否正确。
Method / reasoning	35%	数学、物理、化学尤其重要。
Representation	15%	单位、符号、图表标签、公式格式。
Communication	10%	经济学解释题和 essay 权重更高。

11. MVP 开发路线图

建议按 6-8 周做出可以给母校小范围试用的版本。不要四科同时追求完美。第一科建议从 9709 Mathematics 或 9702 Physics 开始，因为图片中的公式、步骤、单位和 working 最能验证系统核心能力。

11.1 里程碑

阶段	时间	目标	交付物
Phase 0	第 0-3 天	冻结需求与资料边界	PRD、题型清单、版权/资料策略、MVP 范围
Phase 1	第 1-2 周	Web App 骨架和文本问答	登录、聊天界面、科目选择、hint/solve API
Phase 2	第 2-4 周	图片识题流水线	上传、OCR、题目 JSON、低置信处理、引用检索
Phase 3	第 4-5 周	单题批改	学生答案输入/上传、评分 JSON、可读反馈、错因标签
Phase 4	第 5-6 周	四科基本题型支持	9701/9702/9708/9709 prompt/rubric 模板
Phase 5	第 6-8 周	校内 pilot	成本 dashboard、错误日志、反馈表、演示视频

11.2 优先级排序

- 1. 先打通一个闭环：图片上传 -> OCR -> 结构化 -> hint -> full answer -> citations。
- 2. 再做批改：先做 9709/9702 计算题批改，因为评分规则更明确。
- 3. 再扩充科目：9701 加化学概念与计算；9708 加 essay 结构反馈。
- 4. 最后做 dashboard：只展示基本统计，不做复杂画像。

11.3 前端页面

页面	核心组件	备注
/	Landing page、功能展示、登录按钮	突出“会拍照批改 + 中英双语 + 引用来源”。
/app	聊天区、上传区、科目选择、语言模式	MVP 主页面。

/question/<id>	题目图、OCR 结果、提示、答案、引用	方便复盘。
/grade/<id>	学生作答、分数、rubric、错因、建议	重点做漂亮，展示简历价值。
/history	最近题目、按科目筛选	不是完整错题本，但为后续铺路。
/settings	语言模式、API 使用额度、数据删除	体现安全与成本意识。

11.4 GitHub 项目结构

```
{`agentic-tutor/
  apps/
    web/           # Next.js frontend
    api/           # FastAPI backend
  packages/
    shared-types/  # OpenAPI generated types / shared schemas
  services/
    tutor_engine/
      router.py
      prompts/
      rubrics/
      citations.py
      grader.py
    ocr_pipeline/
      preprocess.py
      qwen_ocr.py
      normalize.py
    budget_guard/
      limits.py
      usage.py
  infra/
    docker-compose.yml
    nginx.conf
    migrations/
  data/
    citation_bank_seed/
    eval_sets/
  docs/
    architecture.md
    privacy.md
    evaluation.md
    demo_script.md`}
```

12. 测试、质量、安全与合规

12.1 测试矩阵

测试流	测试内容	MVP 目标
-----	------	--------

Unit tests	路由、schema、prompt assembly、rubric parser	核心编排代码 80%+ 覆盖
OCR tests	清晰印刷、低光、倾斜、手写 working、图表、混合中英	每科至少 30 张图片
Subject eval set	金标准题目、标准提示、标准答案、错因标签	每科至少 50 题
Grading tests	全对、半对、只有方法对、单位错、符号错、essay 缺 evaluation	每种题型 4-6 个 case
Citation tests	每个正式答案都必须有 source id	生产环境 100% pass gate
Cost tests	每条 route token 使用、fallback 频率、日预算	后台报警和自动降级
UX tests	中文优先/英文优先/Exam English、hint 到 solution 流程	找真实学生试用

12.2 低置信与安全输出

这是教育产品，不能为了“看起来聪明”而乱猜。下面几种情况必须触发低置信或要求重拍：

- 题干关键数字、单位、选项缺失。
- 图表坐标轴或曲线不清。
- 学生手写 working 识别不完整。
- OCR 与视觉模型结果冲突。
- 模型评分与规则校验冲突，例如最终答案数值对但单位错。

12.3 隐私与合规

目标用户可能是未成年人，且上传内容包含作业、笔迹、学习表现，因此必须从第一天做数据最小化。中国个人信息保护法把不满十四周岁未成年人的个人信息视为敏感个人信息，生成式 AI 服务公开提供也涉及内容治理要求。MVP 应该按更严格标准设计。

措施	怎么做
最小化收集	只收邮箱/账号、学习记录和必要上传，不收身份证、学校班级等非必要信息。
去 EXIF	上传图片后去掉 GPS、设备信息等元数据。
区域部署	优先选择中国大陆云和国内模型 API，减少跨境数据复杂度。
分离 PII 与学习日志	用户表和 usage/error logs 分开，日志只存 user_id。

删除与导出	提供删除账号、删除上传图、导出学习记录功能。
权限控制	老师账号只能看授权班级/学生，不能随意浏览所有数据。
内容安全	加入违规内容过滤、prompt injection 防护、恶意文件检查。

12.4 版权策略

不要把 Cambridge past papers 和 mark schemes 做成公开可检索题库。更安全的策略是：MVP 使用官方考纲、公式表、学校自编讲义和学生自己上传的问题。真题资料只在学校许可和课堂内部使用范围内处理，不做公开再分发。

13. 后续路线图与简历包装

13.1 后续功能路线

阶段	功能	价值
V1.1	错题本 UI	按错因、科目、topic 聚合错误，生成复习卡。
V1.2	用户画像	识别学生是概念弱、英文弱、计算弱、图表弱还是粗心。
V1.3	老师 dashboard	班级共性错因、题目通过率、作业批改概览。
V1.4	上传教材/讲义建库	让学校和老师上传自己的资料，形成校本知识库。
V1.5	桌面端	支持本地文件夹、截图识题、离线缓存 UI，但模型仍走 API。

13.2 简历项目亮点

这个项目很适合包装成 AI/RAG/agent 工程项目。建议简历 bullet 不要只写 “built a chatbot”，而要强调结构化视觉流水线、工具路由、可解释引用、低成本模型路由和真实用户试用。

英文简历 bullet 示例

Designed and implemented a bilingual agentic tutor for Cambridge A-Level students, combining OCR/VLM question parsing, RAG-based syllabus citation, hint-first tutoring, and rubric-aware grading across Chemistry, Physics, Economics, and Mathematics.

Built a cost-aware model routing pipeline using hosted open-source Chinese LLM APIs, separating OCR, visual fallback, tutoring, and grading routes to keep private-beta inference cost within a constrained monthly budget.

Developed structured question normalization and grading schemas to support explainable feedback, mark-point breakdowns, misconception logging, and future wrong-question notebook/user profiling features.

13.3 Demo 必须展示什么

1. 上传一张数学/物理图片题，展示 OCR 区域、题目 JSON、提示、完整答案。
2. 上传学生作答，展示批改分数、错因标签、单位/步骤反馈。
3. 切换中文优先和 Exam English 模式。
4. 点击引用 chip，展示考纲或讲义片段。
5. 打开后台 usage dashboard，证明你做了成本控制和工程监控。

14. 立即执行清单

优先级	任务	完成标准
P0	确定首个 demo 科目：建议 9709 Mathematics	选 50 道代表题，覆盖代数、微积分、统计/力学基础。
P0	搭建 Next.js + FastAPI + Postgres + Redis	Docker Compose 一键启动。
P0	接入百炼 OpenAI-compatible API	能完成 text chat、OCR、VLM fallback 的最小调用。
P0	完成 Citation Store seed	每科至少 20-40 条考纲/概念/公式片段。
P0	实现 /questions/parse	图片上传后返回 CanonicalQuestion JSON。
P1	实现 hint-first 和 full solution	每次回答结构稳定，并带引用 chips。
P1	实现 grading JSON	输出分数、置信度、错误、下一步建议、错因标签。
P1	建立 eval set	每科至少 20 题先跑通，后续扩到 50+。
P2	实现成本日志和限流	后台显示每个用户、每个 route、每个模型的成本估算。
P2	母校 pilot 准备	准备演示账号、反馈表、隐私说明、使用边界。

15. 资料来源

以下为本方案使用的主要公开资料。价格、政策和模型列表可能变化，上线前应重新核对官方文档。

1. **S1 Cambridge 9701 Chemistry syllabus:** <https://www.cambridgeinternational.org/Images/664563-2025-2027-syllabus.pdf>
2. **S2 Cambridge 9702 Physics syllabus:** <https://www.cambridgeinternational.org/Images/664565-2025-2027-syllabus.pdf>
3. **S3 Cambridge 9708 Economics syllabus:** <https://www.cambridgeinternational.org/Images/697423-2026-2028-syllabus.pdf>
4. **S4 Cambridge 9709 Mathematics syllabus:** <https://www.cambridgeinternational.org/Images/697427-2026-2027-syllabus.pdf>
5. **S5 Alibaba Cloud Model Studio 百炼:** <https://help.aliyun.com/zh/model-studio/what-is-model-studio>
6. **S6 Alibaba Model Studio pricing:** <https://help.aliyun.com/zh/model-studio/model-pricing>
7. **S7 Qwen-VL-OCR:** <https://help.aliyun.com/zh/model-studio/qwen-vl-ocr-api-reference>
8. **S8 Alibaba vision models:** <https://help.aliyun.com/zh/model-studio/vision-model/>
9. **S9 Alibaba batch inference:** <https://help.aliyun.com/zh/model-studio/batch-inference>
10. **S10 Alibaba explicit cache:** <https://help.aliyun.com/zh/model-studio/explicit-cache-best-practice>
11. **S11 Tencent OCR documentation:** <https://cloud.tencent.com/document/product/866/115931>
12. **S12 Tencent OCR pricing:** <https://cloud.tencent.com/document/product/866/17619>
13. **S13 SiliconFlow models:** <https://siliconflow.cn/models>
14. **S14 Education Endowment Foundation - Metacognition:** <https://educationendowmentfoundation.org.uk/education-evidence/guidance-reports/metacognition>
15. **S15 Education Endowment Foundation - Feedback:** <https://educationendowmentfoundation.org.uk/education-evidence/guidance-reports/feedback>
16. **S16 Cambridge past papers policy/help:** <https://help.cambridgeinternational.org/hc/en-gb/articles/115004448905-Where-can-I-find-past-papers-mark-schemes-and-resources-for-our-exams>
17. **S17 Cambridge classroom reproduction guidance:** <https://help.cambridgeinternational.org/hc/en-gb/articles/115004333125-Can-I-reproduce-Cambridge-past-examination-papers-for-use-in-the-classroom-with-my-students>
18. **S18 中华人民共和国个人信息保护法:** https://www.spp.gov.cn/spp/fl/202108/t20210820_527244.shtml
19. **S19 生成式人工智能服务管理暂行办法:** https://www.cac.gov.cn/2023-07/13/c_1690898327029107.htm
20. **S20 个人信息出境相关公开规则:** https://www.cac.gov.cn/2023-02/24/c_1678884830036813.htm